

Análisis de sentimientos: comparativa de las series "Big Bang Theory" y "Silicon Valley"

En este trabajo realizaré un análisis de los sentimientos relacionados con dos series de televisión: "Big Bang Theory" y una serie comparativa en cuanto a tipo y público "Silicon Valley".

La motivación de este análisis es la noticia sobre los millonarios cachés de los protagonistas de la serie "Big Bang Theory". Analizaré si la serie realmente está gustando mucho más que sus comparables y si vale la pena pagar tanto a los actores.

El análisis se realiza en base a los últimos 1000 tweets descargados de tweeter sobre ambas series.

Big Bang Theory

Sillicon Valley

Se procesan los tweets, extrayendo el texto, desglosando en palabras y quitando los caracteres innecesarios y espacios.

```
In [109]: #Con esta función se van a formatear los tweets

def processTweet(tweet):
    tweet = tweet.lowex()
    f www.* or https://to URL
    tweet = re.sub('(swew\.\^\si+))|(https?://(^\si+))', 'URL', tweet)
    #Username to AT USER
    tweet = re.sub('(swew\.\^\si+))|(https?://(^\si+))', 'URL', tweet)
    #Renove additional white spaces
    tweet = re.sub('(*\si+)', '\.\ '\.\ '\.\ '\.\ '\.
    #Replace Nord with word
    tweet = re.sub('fi(^\si+)', '\.'\', tweet)
    #firim
    treet = tweet.strip('\'"')
    return tweet

stopNords = []

#quitando caracteres repetidos
def replaceTwoorMore(s):
    pattern = re.compile(r*(,))\(i,)", re.DOTALL)

In [110]: # Dividimos los tweets en palabras
def getPeatureVector(tweet):
    featureVector = []
    #spile twee into words
    words = tweet.spile()
    for w in words:
        *#spilec two or more with two occurrences
```

Los tweets se clasificarán con la metodología de machine learning, usando el algoritmo Naive Bayes. El entrenamiento realizo con unas listas de palabras positivas y negativas extraídas de Loughran Mc Donald Master Dictionary 2014, con ciertas modificaciones.

```
In [113]: # palabras positivas y negativas que voy a usar para entrenar, podría entrenar con un corpus de tweets etiquetados pero tengo lista de palabras positivos = read_corpus('./positivekcDonalds.cav', 'POS')
no_positivos = read_corpus('./negativeMcDonalds.cav', 'NO_POS')
```

Una ves entrenado el algoritmo se clasifican los tweets entre positivos y no positivos.

Big Bang Theory



Silicon Valley

Finalmente cuento los tweets positivos de ambas series.

```
201
NO_POS
201
NO_POS
201
POS
202
202
202
202 tweets sobre la serie "Big Bang Theory" han sido positivos.
```

Efectivamente la serie "Big Bang Theory" tiene bastantes más tweets positivos.